Requisitos do Assistente de Estoque com IA (linguagem natural)

> Status: **levantamento de requisitos** (nada implementado). Complementa `docs/features-ia.md`, funcionalidade 1. Todas as decisões abaixo foram tomadas em sessão de entrevista com o responsável pelo projeto.

1. Visão geral

Assistente em linguagem natural (português do Brasil) para o Stock Master. O usuário conversa para consultar o estoque; o Admin também pode pedir ajustes de quantidade, sempre com confirmação explícita.

Contexto técnico existente: ASP.NET Core (.NET 10), EF Core, PostgreSQL, Angular (PWA). Leituras de produtos (`GET /api/products` , `/stats` , `/categories` , `/{id}`) disponíveis a qualquer usuário autenticado; escritas restritas à política Admin; rate limiting e `AuditLog` já existentes.

2. Requisitos funcionais

#	Requisito
RF1	**Visualizador:** o assistente só consulta (somente leitura).
RF2	**Admin:** consulta e pode pedir **ajuste de quantidade** (entrada ou saída). Nenhuma outra ação: criar, editar e excluir produtos ficam fora do escopo do assistente.
RF3	O modelo **apenas propõe** o ajuste. Um cartão mostra o estado atual lido do banco, com botões **Confirmar** e **Cancelar**. A confirmação chama o endpoint de ajuste já existente (política Admin e `AuditLog`).
RF4	Conversa com várias trocas. O histórico existe só na sessão do navegador e não é salvo no servidor.
RF5	Restrito ao domínio de estoque. Quando o dado não existe (ex.: não há histórico de movimentações), informa isso claramente e **nunca inventa números**. Assuntos fora do domínio recebem recusa educada e curta, sem sugestões.
RF6	Página dedicada `/assistente` , com o componente de chat isolado para, no futuro, virar painel flutuante.
RF7	Respostas por **streaming (SSE)**, exibindo o estado da operação (ex.: "consultando estoque…").
RF8	Poucas ferramentas de leitura com **filtros parametrizados** (categoria, faixa de preço, abaixo do mínimo, ordenação e limite). Começa com 4 ou 5 ferramentas.
RF9	Busca de produtos **semântica** (embeddings). A funcionalidade 2 (busca semântica) é, portanto, pré-requisito do assistente.

3. Requisitos não funcionais

#	Categoria	Requisito
RNF1	Segurança	O modelo não possui nenhuma ferramenta de escrita. O papel do usuário vem do token de login, nunca do conteúdo do chat.
RNF2	Segurança	Dados de produtos voltam ao modelo como **dados**, não como instruções (mitigação de prompt injection).
RNF3	Precisão	Somas, contagens e valores são calculados pelo banco, nunca pelo modelo.
RNF4	Privacidade	Dados pessoais (ex.: e-mail dos usuários) nunca são enviados ao modelo. Apenas dados de estoque saem para provedores externos.
RNF5	Provedores	**Claude Haiku 5.5** (chat) e **Voyage AI** (embeddings). Chaves apenas em variáveis de ambiente, nunca no git. A API é cobrada por token, separada da assinatura do Claude Code.
RNF6	Custo	Limite por usuário (perguntas por hora e teto diário), pergunta de no máximo ~500 caracteres, histórico enviado limitado às últimas N trocas, `max_tokens` fixo e limite mensal de gastos no Console.
RNF7	Disponibilidade	Assistente isolado do resto do sistema. Timeout de ~30 s, uma nova tentativa em erros temporários, mensagem amigável em português. Sem chave configurada, o item de menu fica oculto ou desativado.
RNF8	Telemetria	`AuditLog` com quem usou, quando e quais ferramentas foram chamadas, mais tokens, latência, modelo, erros e se a proposta foi confirmada ou cancelada. **Não** guarda o texto das conversas.
RNF9	Qualidade	Testes automatizados da parte determinística (LLM simulado); conjunto de avaliação de 20 a 30 perguntas com o modelo real, sob demanda; casos de segurança (prompt injection, Visualizador forçando uma ação, assuntos fora do domínio, pedido de dados de usuários).
RNF10	Infraestrutura	pgvector no Docker local e no Postgres do Render (confirmar suporte antes de começar). Proxy sem buffer para o SSE.
RNF11	Idioma	Respostas sempre em português do Brasil, com tom objetivo.

4. Fora de escopo

- Criar, editar ou excluir produtos pelo assistente.
- Histórico de conversas salvo no servidor.
- Conversa sobre assuntos fora de estoque.
- Painel flutuante em todas as telas (previsto para evolução futura).
- Previsão de reposição (funcionalidade 4) e resumo por e-mail (funcionalidade 5).

5. Decisões registradas

#	Decisão	Escolha
1	O que o assistente pode fazer	Visualizador: leitura. Admin: leitura + ações com confirmação
2	Ações do Admin	Somente ajuste de quantidade
3	Conversa e histórico	Várias trocas, histórico só na sessão
4	Perguntas fora do alcance	Restrito ao estoque, sem sugestões
5	Local no frontend	Página dedicada
6	Entrega da resposta	Streaming (SSE)
7	Provedor de LLM	Claude Haiku 5.5
8	Controle de custo	Limite por usuário + limites de tamanho + limite no Console
9	Confirmação de ações	Modelo propõe; cartão com Confirmar/Cancelar executa
10	Acesso aos dados	Poucas ferramentas com filtros parametrizados
11	Garantia de qualidade	Testes + conjunto de avaliação + casos de segurança
12	Falha do provedor	Isolamento, timeout, uma nova tentativa, mensagem amigável
13	Busca de produtos	Semântica (embeddings) desde a primeira versão
14	Provedor de embeddings	Voyage AI
15	Telemetria	Métricas por chamada, sem guardar texto das conversas

6. Dependências e ordem sugerida

1. Infra de IA: pgvector, serviço de embeddings (Voyage), reindexação ao criar/editar produto (funcionalidade 2).
2. Camada de chat (`IChatService`) com Claude Haiku 5.5, ferramentas de leitura e streaming.
3. Cartão de confirmação do ajuste de quantidade (Admin).
4. Limites de custo, telemetria e tratamento de falhas.
5. Testes e conjunto de avaliação, incluindo casos de segurança.